

ما هي قاعدة بيانات Pima؟

هي مجموعة بيانات طبية استُخدمت للتنبؤ ببداية الإصابة بمرض السكري لدى النساء من قبائل "البِيما" (Pima Indians)، وهم مجموعة من السكان الأصليين الذين يعيشون في ولاية أريزونا الأمريكية.

- لماذا هذه القبيلة تحديداً؟ تاريخياً، تمتلك هذه القبيلة أعلى معدلات انتشار لمرض السكري من النوع الثاني في العالم بسبب التغير المفاجئ في نمط الحياة والجينات، مما جعلها محوراً للدراسات الوراثية والطبية منذ الستينات.

الخصائص الفنية (Dataset Profile) :

تم استخلاص كافة الحالات في هذه القاعدة بناءً على معايير محددة:

- العينة: 768 حالة.
- الجنس: إناث فقط.
- العمر: 21 عاماً فما فوق.
- المتغيرات (Features): تتكون من 8 متغيرات طبية مستقلة (التي استخدمناها في الكود) ومتغير واحد تابع (Outcome) يوضح الحالة (0 سليم، 1 مصاب).

المتغيرات الثمانية (The 8 Predictors) :

هذه المتغيرات لم تُختَر عشوائياً، بل هي المعايير التي حددتها منظمة الصحة العالمية (WHO) آنذاك:

1. Pregnancies: عدد مرات الحمل.
2. Glucose: تركيز الجلوكوز في البلازما بعد ساعتين من اختبار تحمل الجلوكوز الفموي.
3. Blood Pressure: ضغط الدم الانبساطي (ملم زئبق).
4. Skin Thickness: سمك طبقة الجلد للعضلة ثلاثية الرؤوس (ملم).
5. Insulin: مصل الأنسولين لمدة ساعتين (mu U/ml).
6. BMI: مؤشر كتلة الجسم (الوزن بالكجم / الطول بالمتر المربع).
7. Diabetes Pedigree Function: دالة وراثية السكري (تحسب احتمالية الإصابة بناءً على تاريخ العائلة).
8. Age: العمر بالسنوات.

مصدر البيانات (The Source) :

- المصدر الأصلي: المعهد الوطني لأمراض السكري والجهاز الهضمي والكلية في الولايات المتحدة (National Institute of Diabetes and Digestive and Kidney Diseases - NIDDK).
- تاريخ التبرع بالبيانات: تم تقديم هذه البيانات لأول مرة في عام 1988 من قبل الباحث Vincent Sigillito.
- المستودع العالمي: تتوفر حالياً بشكل رسمي في مستودع جامعة كاليفورنيا إيرفين لتعلم الآلة (UCI Machine Learning Repository)، وهو المرجع الذي يعتمد عليه الباحثون حول العالم لتحميلها.

"تم اختيار قاعدة بيانات Pima Indians لهذا المشروع لأنها تُعتبر Standard Benchmark في أبحاث المعلوماتية الصحية. قوة هذه البيانات تكمن في أنها خالية من التحيز الجندري (لأنها ركزت على الإناث) وتوفر علاقات غير خطية معقدة بين الوراثة والمؤشرات الحيوية، مما يجعلها مثالية لاختبار خوارزميات مثل Random Forest."